


KV split P8K/O400 CPU Decode Attention 三层 Profile 总图

workload: prompt=8000, output=400, batch=1, OMP_NUM_THREADS=120 | request wall=25.434s | source time=2026-05-19 15:22:39 UTC


读图方式：第一、二层是 wall-time；第三层是 OpenMP worker 累计 thread-time，只用于定位 C++ inner 内部热点，不能直接和 wall-time 相加。

Layer 1: decode_cpu_path_layer_total = 14.550s




C++ CPU attention op total Decode K/V/slot D2H CPU KV cache write CPU scheduler metadata CPU output alloc
Metadata copy/package excl. scheduler Output H2D Wait prefill D2H stream Query D2H Unattributed outer gap

Layer 2: cpu_attention_cpp_total = 6.606s




C++ inner elapsed C++ op wrapper/profile/boundary gap

Layer 3: C++ inner components = 273.046 thread-s (inner elapsed 4.825s, 56.6 worker-equivalent)



PV tile GEMM + V stream Sync/wait Softmax Paged block lookup Q copy/scale
QK tile GEMM + K stream QK/PV loop other Output/reduce Task acquire/atomic Mask

- 第一层非重叠求和：C++ op + metadata excluding scheduler + scheduler + K/V D2H + CPU KV write + output H2D + wait + Q D2H + alloc + gap = 14.550s。
- 第二层关系：cpu_attention_cpp_total 6.606s = C++ inner elapsed 4.825s + wrapper/profile/boundary gap 1.781s。
- 第三层热点：PV tile 106.183 thread-s，QK tile 95.178 thread-s，二者合计占 C++ inner thread-time 的 73.75%。



Layer 1 读图说明

- decode_cpu_path_layer_total 是每个 decode token、每一层走 CPU attention 路径的外层总 wall-time，累计 14.550s，事件数 12768。

- 本页使用非重叠拆分：decode_metadata_d2h 里的 scheduler 子项被单独拿出来，因此 metadata copy/package excl. scheduler 不会和 CPU scheduler metadata 重复计数。


- 最大单项是 C++ CPU attention op total，为 6.606s，占第一层总时间 45.40%。

- 未归因外层 gap 为 3.463s，占 23.80%；它不是某个已知算子，而是当前外层 timer 覆盖但还没有单独插桩的边界开销。

- 下一页给出 Layer 1 每个耗时项的具体含义。

Layer 1 各耗时项含义


耗时项	时间	占比	具体操作
C++ CPU attention op total	6.606 s 0.517 ms/层-token	45.40%	调用 vLLM 原生 CPU paged attention C++ op 的外层累计时间；包含 C++ inner、op wrapper、profile 边界等。
Unattributed outer gap	3.463 s 0.271 ms/层-token	23.80%	decode CPU path 外层 timer 覆盖但尚未单独插桩的时间，可能包含 profile JSONL 写入、Python glue、torch/C++ 边界和小同步副作用。
Metadata copy/package excl. scheduler	1.114 s 0.087 ms/层-token	7.66%	query_start_loc、seq_lens、block_table 等 metadata 的 GPU->CPU 小 tensor 拷贝、dtype 转换、CPU tensor 分配和 Python 打包；不含 scheduler metadata 子项。
Decode K/V/slot D2H	0.742 s 0.058 ms/层-token	5.10%	decode 新生成 K、V 以及 slot_mapping 等小 tensor 从 GPU 同步搬到 CPU，供 CPU KV cache 写入。
Output H2D	0.715 s 0.056 ms/层-token	4.91%	CPU attention 输出从 CPU pinned memory 拷回 GPU output tensor，供后续 GPU 算子继续执行。
CPU KV cache write	0.684 s 0.054 ms/层-token	4.70%	把 decode 阶段新 token 的 K/V reshape 后写入 CPU paged KV cache，对应 CPU cache 更新路径。
Wait prefill D2H stream	0.530 s 0.042 ms/层-token	3.64%	decode 进入 CPU attention 前等待该层 prefill KV cache 的异步 D2H stream 完成。
CPU scheduler metadata	0.310 s 0.024 ms/层-token	2.13%	调用 C++ get_scheduler_metadata 生成 CPU paged attention 调度元数据，包括 work item、KV split/reduction 信息等。
Query D2H	0.247 s 0.019 ms/层-token	1.70%	当前 decode query 从 GPU tensor 同步搬到 CPU tensor，作为 CPU attention 的 Q 输入。
CPU output alloc	0.140 s 0.011 ms/层-token	0.96%	为 CPU attention 输出分配 CPU pinned tensor。



Layer 2 各耗时项含义

耗时项	时间	占比	具体操作
C++ inner elapsed	4.825 s	73.04%	C++ CPU attention 内部 wall-time 计时，覆盖 worker 并行区内主要 attention 执行路径。
C++ op wrapper/profile/boundary gap	1.781 s	26.96%	cpu_attention_cpp_total 中未落入 C++ inner elapsed 的部分，包含 torch custom op dispatch、C++ wrapper 参数处理、profile 写入和返回边界等。

解释：cpu_attention_cpp_total 是 Python 侧调用 C++ CPU attention op 的外层计时；C++ inner elapsed 是 C++ op 内部额外记录的 kernel 主体 elapsed。两者差值不是计算核心本身，而是 wrapper、参数处理、custom op dispatch、profile 输出和边界开销。因此优化 QK/PV tile 只能覆盖 C++ inner 的一部分，无法自动消除第二层 wrapper gap。



Layer 3 读图说明

- C++ inner elapsed 是 4.825s；本页条形图使用的是 OpenMP worker 累计 thread-time，总和 273.046 thread-s。

- thread-time / elapsed 约为 56.6 worker-equivalent，表示并行 worker 消耗的累计时间，不应和 Layer 1/2 wall-time 直接相加。

- PV tile GEMM + V stream 和 QK tile GEMM + K stream 合计 201.361 thread-s，占 C++ inner thread-time 的 73.75%，是 C++ inner 内部最主要热点。

- 下一页给出 C++ inner 每个耗时项的具体含义。

Layer 3 各耗时项含义

耗时项	时间	占比	具体操作
PV tile GEMM + V stream	106.183 s	38.89%	P×V tile 计算及 V cache 流式读取；在当前 profile 中是最大 thread-time 热点。
QK tile GEMM + K stream	95.178 s	34.86%	Q×K tile 计算及 K cache 流式读取；负责生成 attention score。
Sync/wait	22.269 s	8.16%	KV split 并行区里的 split barrier 和 reduce flag 等同步等待。
QK/PV loop other	15.196 s	5.57%	QK/PV 主循环中未归到 tile GEMM、block lookup 的其他循环控制和边界处理。
Softmax	14.813 s	5.42%	对 attention score 做 online softmax，包括 max/sum 维护和概率归一化。
Output/reduce	14.085 s	5.16%	partial output 写入、split reduction 和 final output 写回；KV split 下用于合并多个 split 的结果。
Paged block lookup	2.667 s	0.98%	根据 block_table 查找 paged KV cache block 的地址/索引，包含 QK 和 PV 两段 lookup。
Task acquire/atomic	2.244 s	0.82%	OpenMP worker 通过 atomic/fetch-add 等方式领取 work item 的开销。
Q copy/scale	0.367 s	0.13%	将 Q 拷贝/缩放到 CPU kernel 使用的局部格式。
Mask	0.045 s	0.02%	causal/sliding-window mask 等 score 屏蔽操作。

总体结论

- 第一层看真实 decode CPU path 成本；第二层看 C++ op 外层调用成本；第三层只看 C++ inner 的线程级热点。

- 当前 profile 的主要结论是：外层 C++ op 之外还有明显 metadata、D2H/H2D、CPU KV write 和未归因 gap；C++ inner 内部则以 QK/PV tile 路径为主。

- Paged block lookup 与 task acquire 占比很小，不是当前 profile 的主瓶颈。

- 该图使用已有 profile 结果生成，没有重新运行服务。