




End-to-end request wall



Model forward attribution



Mutually exclusive request breakdown



核心读数

GPU default request wall: 3.412 s

GPU forced eager request wall: 4.528 s

Heter request wall: 21.858 s

Heter skip CPU compute request wall: 12.488 s

Heter decode_cpu_path_layer_total: 11.038 s

Heter - GPU default: 18.446 s

Heter - GPU forced eager: 17.330 s

Heter wall - CPU decode - GPU default wall: 7.408 s

Heter wall - CPU decode - GPU eager wall: 6.292 s

Heter - skip-compute wall delta: 9.370 s

GPU eager - GPU default: 1.116 s

Skip-compute - GPU eager: 7.960 s

解释口径

1. GPU forced eager 只比 GPU default 慢约 1s，关闭 CUDA Graph 不是主要矛盾。
2. Heter 必须关闭 decode CUDA Graph，因为 CPU attention 分支含 GPU->CPU->GPU 同步。
3. skip-compute 组保留异构同步和数据搬运，只跳过 C++ CPU attention 计算。
4. skip-compute 仍显著慢于 GPU eager，主要指向每层同步/往返和路径串行化。
5. Heter 与 skip-compute 的差值近似代表 C++ CPU attention 计算及其依赖输出带来的增量。
6. 高频 JSONL/逐层日志不作为性能口径，本实验只使用 memory summary。